Do Simbólico à Incerteza em Focos de Fogo na Amazônia: um Pipeline de IA de Seis Etapas

Equipe 9 — Matheus Garcia
Fundamentos de Inteligência Artificial — Prof. Edjard Mota

Resumo

Percorremos o pipeline do curso — árvore de decisão, regressão linear e logística, probabilidade, Naive Bayes com EM, rede Bayesiana e lógica fuzzy — sobre detecções de focos de fogo do bioma Amazônia (INPE, sensor AQUA_M-T, 2024). A tarefa é priorizar focos já detectados de acordo com a potência radiativa (FRP). Todos os algoritmos foram implementados do zero em NumPy e comparados com scikit-learn, scikit-fuzzy e pgmpy. Os modelos individuais têm poder preditivo modesto (AUC média entre 0,58 e 0,64) e nenhum alcança probabilidade de 0,5 para a classe de interesse, de modo que o limiar rígido tem recall zero. O sistema fuzzy Mamdani, com quatro entradas e seis regras legíveis, recupera 81% dos focos de FRP elevada, ao custo de precisão de 0,29. Discutimos por que esse ganho de recall deve ser lido com cautela.

1 Introdução e dados

O trabalho adota a filosofia auto-contida da especificação de 15/10/2026: cada etapa aplica uma técnica diferente ao mesmo domínio oficial (*Meio Ambiente*) e as saídas alimentam as etapas seguintes. A fonte é o Programa Queimadas do INPE (catálogo em `dados.gov.br`, consulta em 31/10/2026). O recorte é bioma Amazônia, sensor AQUA_M-T, com desenvolvimento em 2024 (140 346 detecções, 531 municípios) e teste reservado em 2025 (43 131 detecções). A unidade de análise é uma detecção em um pixel e horário, não um incêndio.

Os seis atributos são `numero_dias_sem_chuva`, `precipitacao`, `lat`, `lon`, `mes` e `hora_utc`. O alvo contínuo é a FRP (MW; mediana 27,3, Q75 58,4, máximo 8 094,3). O alvo binário é $F = 1$ se FRP $\geq$ Q75 do treino, aprendido em cada fold (57,9–59,5 MW), o que dá cerca de 25% de positivos. Trata-se de um rótulo estatístico, sem equivalência automática com gravidade ambiental.

Protocolo. Cinco folds espaciais (`GroupKFold` por município), de modo que nenhum município aparece em treino e validação ao mesmo tempo. Imputação pela mediana, padronização e Q75 são calculados somente no treino. Há também cinco folds temporais como diagnóstico separado. **O ano de 2025 não foi usado para ajustar, selecionar ou avaliar modelos**; permanece reservado. Resultados são média sobre os folds, com seed fixa 42.

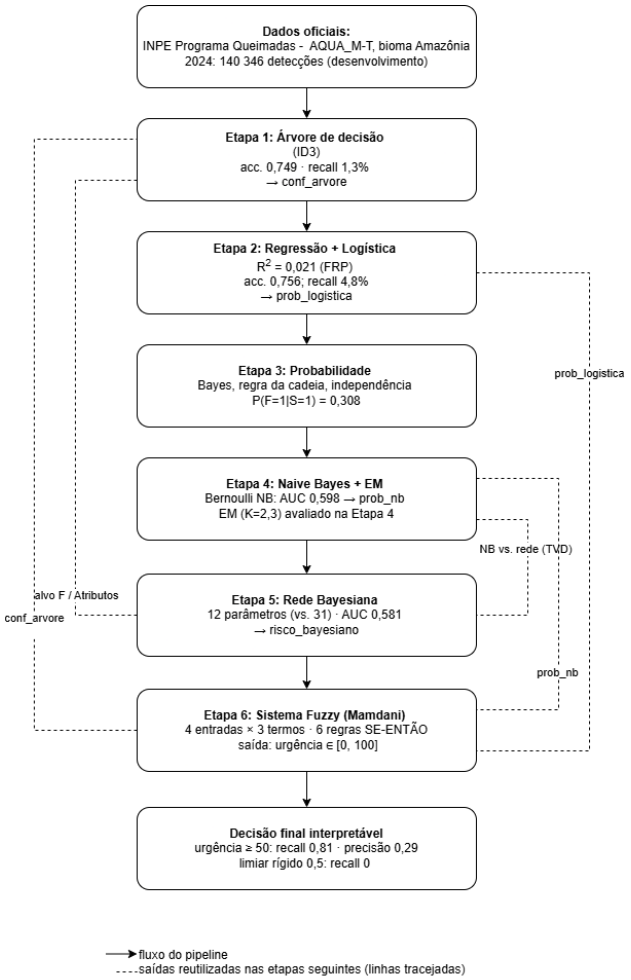


Figura 1: Diagrama de integração. Setas cheias: fluxo do pipeline; tracejadas: saídas reutilizadas em etapas posteriores.

2 Etapas 1 e 2 — Aprendizado simbólico e linear

Árvore de decisão (Etapa 1). Implementamos entropia, ganho de informação e ID3 do zero (sem parada por ganho nulo, necessária para aprender XOR, como verificamos em testes sintéticos) sobre os seis atributos binarizados na mediana do treino, e comparamos com `DecisionTreeClassifier` (critério entropia): as métricas coincidem fold a fold. No fold 0, a raiz escolhe `numero_dias_sem_chuva` (ganho de 0,0143 bits), e o segundo nível usa `lon` (0,0030) e `lat` (0,0057); ganhos tão pequenos já indicam pouco sinal. A acurácia média é 0,749 (±0,015), igual à do classificador de maioria (0,750), com recall de 1,3% para $F = 1$. Como a classe positiva é o quartil superior, prever quase sempre 0 já rende acurácia alta; por isso reportamos também precisão, recall e F1. A discretização perde informação (no fold 0, a precipitação tem mediana zero e vira constante). No diagnóstico temporal dentro de 2024 a acurácia é 0,746 (±0,118) contra 0,738 da maioria, mostrando forte sensibilidade ao período.

Monotonicidade. Num exemplo sintético, o ramo $X{=}0$ começa com uma observação de cada classe e prevê 0 por desempate; ao acrescentar um exemplo $X{=}0$ de classe 1, a maioria passa a 1, ainda que todas as observações anteriores sejam mantidas. A indução é, portanto, revisável (não monotônica): novas evidências podem levar ao abandono de uma hipótese, ao contrário da consequência lógica clássica, em que premissas adicionais preservam as conclusões.

Regressão e logística (Etapa 2). A FRP tem cauda longa (média 64,2 MW, mediana 27,3, percentil 99 de 619, máximo 8 094). Implementamos a regressão univariada por fórmula fechada (sobre dias sem chuva: 0,548 MW por dia no fold 0), a multivariada e o Ridge por gradiente

descendente sobre atributos padronizados (convergência com norma do gradiente $\leq 10^{-7}$ em cerca de 1 200 iterações) e a logística com sigmoide estável. A Tabela 1 mostra que o R^2 é muito baixo (0,021 na multivariada): os seis atributos explicam pouco da FRP. Na grade $\lambda \in \{0, 10^{-3}, \ldots, 10\}$, o menor RMSE médio ocorre em $\lambda = 0{,}01$, mas a melhora sobre $\lambda = 0$ é mínima e a escolha usou a própria validação de 2024; na curva de coeficientes, a penalização reduz a norma dos pesos, em especial os de `hora_utc` e `lon`. A logística tem acurácia 0,756, precisão 0,677 e recall 0,048. As versões próprias e as do scikit-learn concordam (diferença máxima de coeficientes $4{,}9 \times 10^{-7}$ e de probabilidades $1{,}1 \times 10^{-6}$). No diagnóstico temporal, o R^2 médio da multivariada é negativo ($-0{,}037$) e a acurácia da logística (0,734) fica abaixo da maioria (0,738).

Modelo	**R^2 / Acurácia**	**Precisão**	**Recall**	**F1**
Média do treino (regressão)	$-0{,}001$	—	—	—
Univariada	0,011	—	—	—
Multivariada / Ridge (λ=0,01)	0,021	—	—	—
Maioria (classificação)	0,750	0	0	0
ID3	0,749	0,365	0,013	0,025
Regressão logística	0,756	0,677	0,048	0,089

Tabela 1: Etapas 1 e 2, média de cinco folds espaciais (classe positiva: FRP $\geq$ Q75).

3 Etapas 3 a 5 — Probabilidade, Naive Bayes + EM e rede Bayesiana

Probabilidade (Etapa 3). Definimos eventos binários com cortes aprendidos no treino: F (FRP $\geq$ Q75), S (período longo sem chuva, ≥ 10 dias), R (chuva no instante da detecção, > 0 mm), H (hora UTC $\geq 18{,}1$) e M (mês ≥ 9). Na conjunta de F e S (fold 0, $n = 112\,277$), $P(F{=}1) = 0{,}250$ e $P(S{=}1) = 0{,}524$. Pelo Teorema de Bayes, a informação diagnóstica $P(S{=}1 \mid F{=}1) = 0{,}645$ converte-se na causal $P(F{=}1 \mid S{=}1) = 0{,}308$, contra $P(F{=}1 \mid S{=}0) = 0{,}187$: diferença de 0,121 (IC 95% por *bootstrap* de municípios: 0,098 a 0,142) e razão de 1,65. Por faixas de dias sem chuva, a proporção de $F{=}1$ cresce de 0,163 (< 3 dias) a 0,396 (≥ 81 dias). Como os dados são observacionais, isso não prova causalidade; e a lógica de primeira ordem não expressa o fato, pois "período longo implica FRP elevada" é falsa, enquanto o verdadeiro é uma proporção. A regra da cadeia $P(R, S, F) = P(R)P(S \mid R)P(F \mid S, R)$ reproduz os oito eventos atômicos. A diferença é estável nos cinco folds ($0{,}122 \pm 0{,}006$ no treino e $0{,}123 \pm 0{,}024$ na validação) e robusta a casos completos e a S definido pelo Q75 (0,128 a 0,134).

S e R *não* são condicionalmente independentes dada a classe ($\phi = -0{,}307$ em $F{=}0$ e $-0{,}328$ em $F{=}1$; informação mútua de 0,073 bits), a dependência mais forte entre os pares de atributos, seguida de S–M ($\phi \approx -0{,}27$) e R–M ($\phi \approx +0{,}18$). Isso viola a hipótese do Naive Bayes e motivou a estrutura da Etapa 5. A Etapa 3 não é entrada do sistema fuzzy porque não produz uma probabilidade de F por exemplo, apenas define eventos e cortes.

Naive Bayes e EM (Etapa 4). Implementamos MLE e MAP com prior Beta$(2, 2)$ para a Bernoulli: com cerca de 112 mil exemplos por treino, as duas estimativas da frequência de F ($\approx 0{,}250$) praticamente coincidem, e a prior só pesa em amostras pequenas. O Naive Bayes de Bernoulli ($\alpha = 1$) bate com o do scikit-learn (diferença máxima de $5{,}7 \times 10^{-6}$), mas com limiar 0,5 não prevê nenhum positivo (acurácia 0,750, recall 0), pois suas probabilidades ficam entre 0,13 e 0,40. A AUC de validação é 0,598, o que indica algum poder de ordenação.

Para a variável oculta Z, ajustamos por EM misturas gaussianas de covariância diagonal em cada classe, com $K = 1$ (Gaussian NB), $K = 2$ e $K = 3$ perfis. A log-verossimilhança de treino cresce de forma monótona e o EM converge em 9 a 32 iterações no fold 0. A Tabela 2 mostra que o EM *não* melhora o Naive Bayes de forma consistente: $K = 2$ eleva a acurácia, mas reduz o recall; $K = 3$ eleva o recall e o F1, mas piora a AUC (de 0,637 para 0,595).

Modelo	Acurácia	Precisão	Recall	F1	AUC
Gaussian NB (K=1)	0,711	0,375	0,252	0,295	0,637
NB + EM (K=2)	0,721	0,388	0,208	0,261	0,633
NB + EM (K=3)	0,665	0,325	0,310	0,310	0,595

Tabela 2: Etapa 4, média de cinco folds espaciais (limiar 0,5).

Rede Bayesiana (Etapa 5). O DAG (Figura 2) tem cinco arestas, $M \to R$, $M \to S$, $R \to S$, $S \to F$ e $H \to F$, e fatora a conjunta como $P(M)P(H)P(R \mid M)P(S \mid M, R)P(F \mid S, H)$. As arestas entre M, R e S modelam a dependência meteorológica que o Naive Bayes ignora; $S \to F$ e $H \to F$ expressam a estiagem acumulada e o ciclo diurno como causas da FRP elevada. Com apenas 12 parâmetros livres contra $2^5 - 1 = 31$ da conjunta, a rede economiza 19 números (61,3%). As CPTs foram estimadas por máxima verossimilhança em cada treino; por exemplo, $P(F{=}1 \mid S{=}1, H{=}0) = 0{,}317$ e $P(F{=}1 \mid S{=}0, H{=}0) = 0{,}184$ no fold 0.

A inferência por enumeração, implementada do zero, coincide com o `VariableElimination` do pgmpy em 11 consultas causais, diagnósticas e intercausais (diferença máxima $1{,}1 \times 10^{-16}$; Figura 3). A d-separação foi verificada em duas independências, $M \perp F \mid S$ e $R \perp H \mid S$ (e, por contraste, $M \not\perp F$ sem observar S). O colisor $S \to F \leftarrow H$ mostra *explaining away*: sem observar F, $P(S{=}1 \mid H) = 0{,}524$ para qualquer H; ao observar $F{=}1$, passa a 0,655 se $H{=}0$ e 0,635 se $H{=}1$. Comparada ao Naive Bayes, a rede reproduz melhor a distribuição conjunta (distância de variação total na validação 0,179 contra 0,243), mas não ordena melhor os exemplos: AUC 0,581 contra 0,598, com log-loss praticamente igual (0,553).

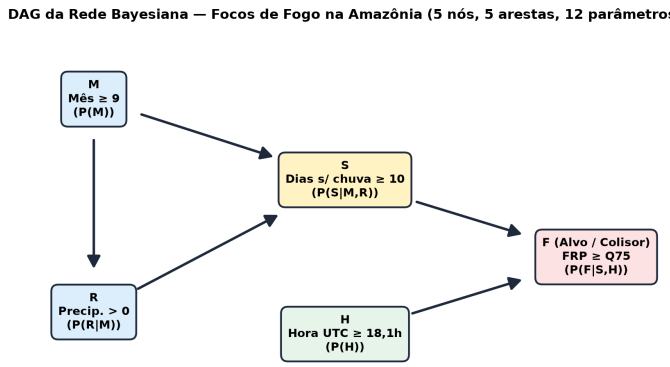


Figura 2: DAG da rede Bayesiana: 5 nós, 5 arestas e 12 parâmetros livres.

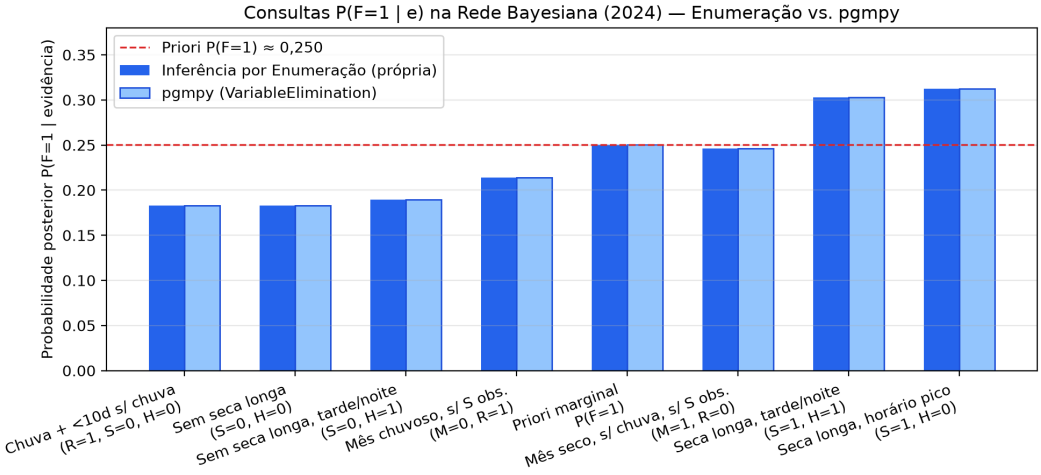


Figura 3: Consultas $P(F{=}1 \mid e)$ na rede ajustada em 2024: enumeração própria e pgmpy coincidem.

4 Etapa 6 — Sistema de inferência fuzzy Mamdani

4.1 Motivação

Nenhum modelo individual produz $P(F{=}1)$ acima de 0,5: as probabilidades das Etapas 2, 4 e 5 ficam em torno de 0,20–0,35. O limiar rígido de 0,5 aplicado à rede Bayesiana nunca prioriza foco algum (recall 0). O sistema fuzzy combina as quatro fontes disponíveis em um índice de *urgência* graduado em $[0, 100]$.

4.2 Variáveis linguísticas e funções de pertinência

As entradas são `conf_arvore` (proporção de classe 1 na folha ID3), `prob_logistica`, `prob_nb` e `risco_bayesiano` (Etapas 1, 2, 4 e 5). Cada uma tem três termos triangulares (baixo, médio, alto), calibrados à faixa observada em 2024, e a saída `urgencia` tem os termos baixa, média e alta. A função triangular com suporte $[a, c]$ e pico em b é

$$\mu(x; a, b, c) = \max\Big(\min\Big(\tfrac{x-a}{b-a}, \tfrac{c-x}{c-b}\Big), 0\Big). \tag{1}$$

Variável	baixo	médio	alto
`risco_bayesiano`	(0; 0; 0,22)	(0,18; 0,25; 0,32)	(0,28; 0,35; 0,50)
`prob_nb`, `prob_logistica`	(0; 0; 0,20)	(0,16; 0,24; 0,32)	(0,28; 0,36; 0,50)
`conf_arvore`	(0; 0; 0,30)	(0,20; 0,50; 0,80)	(0,70; 1; 1)
`urgencia`	(0; 0; 40)	(30; 50; 70)	(60; 100; 100)

Tabela 3: Parâmetros $(a; b; c)$ das funções de pertinência.

4.3 Regras e inferência

As seis regras (E = mínimo) são legíveis por um especialista:

R1: SE `risco_bayesiano` é alto E `prob_nb` é alto ENTÃO urgência é alta.

R2: SE `prob_logistica` é alto E `risco_bayesiano` é alto ENTÃO urgência é alta.

R3: SE `conf_arvore` é alto E `risco_bayesiano` é alto ENTÃO urgência é alta.

R4: SE `prob_logistica` é médio E `prob_nb` é médio ENTÃO urgência é média.

R5: SE `conf_arvore` é médio E `risco_bayesiano` é médio ENTÃO urgência é média.

R6: SE as quatro fontes são baixas ENTÃO urgência é baixa.

Para uma regra r com antecedentes $A_{r,i}$, a força é $w_r = \min_i \mu_{A_{r,i}}(x_i)$. A saída agregada é $\mu(u) = \max_r \min\big(w_r, \mu_{C_r}(u)\big)$, defuzzificada por centroide, $u^* = \sum_u u\,\mu(u) / \sum_u \mu(u)$. O sistema foi implementado do zero em NumPy (`fuzzy.py`, com versão vetorizada `avaliar_lote`) e verificado contra o `scikit-fuzzy` em 100 pontos nos quais ao menos uma regra dispara, com diferença máxima tolerada de 0,5 ponto (discretização das grades). O exemplo da especificação (`risco` = 0,75) devolve urgência alta, como esperado.

4.4 Resultados

Em cada fold, os quatro modelos são ajustados no treino e as saídas de validação alimentam o sistema. A decisão fuzzy (urgência ≥ 50) é comparada ao limiar rígido de 0,5 sobre a rede Bayesiana (Tabela 4).

Decisão	**Precisão**	**Recall**	**AUC**
Limiar rígido $P \geq 0{,}5$ (rede Bayesiana)	—	0	0,581
Fuzzy, urgência ≥ 50	0,29	0,81	—

Tabela 4: Etapa 6, média dos cinco folds espaciais.

O recall sobe de 0 para 0,81, mas a precisão de 0,29 está próxima da taxa-base ($\approx 0{,}25$). Com prevalência de 25%, essa combinação implica sinalizar aproximadamente 70% das detecções, com ganho de precisão de apenas cerca de 1,2 vez sobre o sorteio. Uma possível explicação: com as demais entradas em valores médios, a urgência nunca cai abaixo de 50, pois as regras 4 e 5 ("consenso moderado") produzem exatamente o centro do termo *média*. Como 50 é também o corte de decisão, concordância moderada já conta como positivo. O ganho de recall vem sobretudo dessa escolha de corte, não de nova informação.

5 Discussão e limitações

Interpretabilidade. Cada regra traduz uma condição de concordância entre fontes e pode ser lida por um especialista, em contraste com o limiar rígido, que descarta todos os focos. A saída é graduada, o que permite *priorizar* (ordenar) e não só decidir.

Quando o fuzzy supera o limiar rígido. Quando as probabilidades são mal calibradas e concentradas em faixa estreita, como aqui. Mas o fuzzy não cria sinal: as AUCs da rede Bayesiana e do Naive Bayes (0,58 e 0,60) mostram que a informação nos seis atributos é escassa. Um corte de urgência mais alto (p.ex. 60) ou uma curva precisão–recall indicariam melhor o compromisso; sugerimos isso como trabalho futuro.

Limitações. (i) Os valores esperados do enunciado (acurácia 72–80%, R^2 0,55–0,82) não foram usados como metas e não foram atingidos; os dados contêm apenas detecções e atributos meteorológicos do próprio INPE. (ii) Detecções próximas não são independentes, mesmo com folds por município. (iii) As funções de pertinência foram calibradas à mão na faixa de 2024, sem otimização. (iv) A urgência é um índice ordinal, não uma probabilidade calibrada. (v) O hiperparâmetro λ do Ridge foi escolhido na própria validação espacial. (vi) FRP mede potência radiativa do pixel, não área queimada nem prioridade operacional. (vii) A avaliação em 2025 ainda não foi realizada.

6 Conclusão

O pipeline mostrou, etapa a etapa, como a incerteza passa de rótulos duros (árvore) a probabilidades (logística, Naive Bayes, rede) e a graus de pertinência (fuzzy). O resultado principal é negativo e instrutivo: com atributos fracos, nenhuma técnica gera um bom classificador, e o sistema fuzzy serve mais como ferramenta transparente de priorização do que como ganho preditivo.

Reprodutibilidade. Código, notebooks por etapa e dados em `https://github.com/Murillo-Rafael/Meio-Ambiente---Equipe-9`; Python 3.12, seed 42. Prompts e escolhas assistidas por IA estão documentados em `docs/uso-de-ia.md` (apêndice exigido).

Referências

[1] INPE. *Programa Queimadas: focos mensais, Brasil.* `https://dados.gov.br/dados/conjuntos-dados/monitoramento-de-queimadas`. Acesso em 31/10/2026.

[2] Russell, S.; Norvig, P. *Artificial Intelligence: A Modern Approach.* 4. ed., Pearson, 2020.

[3] Zadeh, L. A. Fuzzy sets. *Information and Control*, 8(3):338–353, 1965.

[4] Hüllermeier, E. Fuzzy machine learning and data mining. *WIREs DMKD*, 1(4):269–283, 2011.

Apêndice — Uso de inteligência artificial

Seguindo a especificação, registramos o uso de assistentes de IA. O registro completo (data, assistente e texto integral dos prompts) está em `docs/uso-de-ia.md` do repositório. As decisões críticas foram tomadas pela equipe: foco nos focos já detectados (e não na previsão de novas ocorrências), bioma Amazônia, 2024 para desenvolvimento e 2025 para teste (sensor AQUA_M-T) e rótulo pelo percentil 75 da FRP.

Parte	**Assistente**	**Solicitação (resumo)**
Dados e Etapas 1–2	Codex (31/10/2026)	Construir e auditar o dataset de 2024–2025; guia de implementação de `arvore.py`, `linear.py` e dos notebooks; revisão dos resultados.
Etapa 3	Claude (01/11/2026)	Investigar como a proporção de FRP elevada varia com períodos longos sem chuva: conjunta, marginais e condicionais, regra da cadeia, Bayes e independência condicional, com cortes aprendidos no treino.
Etapa 5	Antigravity/Gemini (06/11/2026)	Explicar a parte 5, conferir as partes 1–4 e implementar a rede Bayesiana, com verificação ao fim de cada etapa.
Etapa 6	DeepSeek (06/11/2026)	Combinar as saídas das Etapas 1, 2, 4 e 5 em um sistema Mamdani, com urgência em $[0, 100]$, seis regras e comparação com o limiar 0,5, mantendo 2025 reservado.
Relatório e slides	Claude	Redação a partir dos notebooks e do README do repositório.